

Découverte d'Oracle APEX

Introduction aux statistiques descriptives

Ophélie Fraisiert-Vannier

2024 – 2025

1 Différence moyenne / médiane : calculez la moyenne et la médiane des 2 variables ci-dessous à l'aide d'un tableur

Variable A	23	12	15	12	11	19	17	17	20	14
Variable B	16	17	17	17	18	17	17	18	17	1630

2 Analyses de base à partir d'un fichier CSV

Récupérer sur Moodle le fichier `Données Ex2`.

La page suivante décrit les données qu'il contient : <https://data.toulouse-metropole.fr/explore/dataset/caniparcs/information/>

2.1 Calculez le minimum, le maximum, la moyenne et la médiane de la variable `surface_m2`.

Résultats attendus :

Surface minimale (m ²)	4,00
Surface maximale (m ²)	735,00
Surface moyenne (m ²)	171,56
Surface médiane (m ²)	112,00

2.2 Calculez l'étendue, l'écart interquartiles, l'écart-type et la variance de la variable `surface_m2`.

Résultats attendus :


Étendue (m ²)	731,00
Écart inter-quartiles (m ²)	177,75
Écart-type de la surface (m ²)	174,00
Variance de la surface ((m ²) ²)	30274,41

3 Distribution et régression linéaire


Téléchargez le fichier CSV à l'adresse suivante : <https://ressources.data.sncf.com/explore/dataset/frequentation-gare/information/>

3.1 Représentez graphiquement la distribution de la variable Total Voyageurs 2023 arrondi au million sous forme d'effectifs et de fréquences cumulées.


Pour arrondir au million, regarder la documentation de la fonction `ARRONDI.AU.MULTIPLE`.




3.1.1 Sur le graphe d'effectifs, passez l'axe des ordonnées en échelle logarithmique et observez les changements.



3.2 Calculez la droite de régression et le coefficient de détermination entre les variables Total Voyageurs 2023 et Total Voyageurs 2022. Commentez le résultat.



3.3 Mêmes questions pour les variables Total Voyageurs 2023 et Total Voyageurs 2015. Quelle conclusion en tirez-vous ?




4 Dans APEX

Les exercices suivants sont à faire dans l'application APEX créée lors du TP2.

4.1 Créez une nouvelle page nommée "Statistiques" dans laquelle vous afficherez les informations suivantes :

- Salaire moyen des employés de l'entreprise
- Salaire médian
- Distribution des salaires dans l'entreprise



Vous pouvez partir d'une page de type "Dashboard" si vous préférez ne pas partir d'une page blanche.

4.1.1 Détails techniques des composants affichant les salaires moyen et médian

- *Column Span* : 1 (réglable dans la section *Layout* du graphe)
- Type de graphe : *Status Meter Gauge*
- Orientation : Vertical
- Show Plot Area : Oui
- Format des valeurs : *Currency*
- Valeurs affichées :
 - Value : salaire moyen ou médian
 - Minimum Value : salaire min dans l'entreprise
 - Maximum Value : salaire max dans l'entreprise

4.1.2 Détails techniques du composant affichant la distribution


- *Column Span* : 8 (réglable dans la section *Layout* du graphe)
- Type de graphe : *Bar*
- Orientation : Vertical
- Valeurs affichées :
 - X : salaires
 - Y : nombres d'employés avec ce salaire

4.2 Créer une vue présentant pour chaque employé son ID, son salaire, et son ancienneté en jour ($\text{seniority_days} = \text{hire_date} - \text{jour courant}$)

Les vues peuvent être créées via l'*Object Browser* du *SQL Workshop*

COR_SALARY_SENIORITY		
Columns	Code	Data
Errors	Grants	Dependencies
DDL		
Columns...	Filter...	Count Rows
Download	Refresh	
EMPLOYEE_ID	SALARY	SENIORITY_DAYS
198	2600	6462
199	2600	6256
200	4400	7835

4.3 Dans la page créée lors de l'exercice précédent, ajoutez un graphe présentant en abscisse les salaires et en ordonnée l'ancienneté en jours



Il est possible de calculer une régression linéaire en SQL pur même si l'expérience est un peu compliquée. Les éléments de l'équation de la droite de régression linéaire $Y = aX + b$ peuvent être calculé comme suit :

$$a = \frac{\text{Covariance}(X, Y)}{\text{Var}(X)} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \text{Avg}(X))(y_i - \text{Avg}(Y))}{\text{Var}(X)}$$

$$b = \text{Avg}(y) - a * \text{Avg}(x)$$

$$R^2 = \left(\frac{\text{Covariance}(X, Y)}{\sigma_X * \sigma_Y} \right)^2$$

Nous allons commencer par créer une nouvelle vue permettant de calculer pour chaque élément des variables `salary` et `seniority_days` leur écart à la moyenne et le produit de ces 2 écarts, dont nous avons besoin pour calculer la covariance.

```
1 CREATE VIEW "REGRESSION" AS
2 select
3     a.employee_id,
4     a.salary,
5     a.seniority_days,
6     a.salary-b.avg_salary as ecart_salary,
7     a.seniority_days-b.avg_seniority as ecart_seniority,
8     (a.salary-b.avg_salary) * (a.seniority_days-b.avg_seniority) as cov_part
9 from
10    cor_salary_seniority a,
11    (select avg(salary) as avg_salary, avg(seniority_days) as avg_seniority
12       from cor_salary_seniority) b;
```

REGRESSION						
Columns Code Data Errors Grants Dependencies DDL						
Columns... Filter... Count Rows Download Refresh						
EMPLOYEE_ID	SALARY	SENIORITY_DAYS	ECART_SALARY	ECART_SENIORITY	COV_PART	
198	2600	6462	-3861.831775700934579439...	-588.822429906542056074...	2273933.17005852039479430...	
199	2600	6256	-3861.831775700934579439...	-794.8224299065420560747...	3069470.515852912918158791...	
200	4400	7835	-2061.831775700934579439...	784.17757009345794392523...	-1616842.23181063848371036...	
201	13000	7682	6538.1682242990654205607...	631.17757009345794392523...	4126745.13267534282470084...	
202	6000	7135	-461.8317757009345794392...	84.17757009345794392523...	-38875.8766704515678225172...	
203	6500	8302	38.168224299065420560747...	1251.17757009345794392523...	47755.2261332867499344920...	

Nous pouvons maintenant calculer les valeurs dans notre cas avec la requête suivante :

```

1 select
2   round(sum(cov_part)/count(employee_id)/variance(salary), 2) as a,
3   round(
4     avg(seniority_days) - sum(cov_part)/count(employee_id)/variance(salary)*avg(salary),
5     2) as b,
6   round(
7     power(
8       (sum(cov_part)/count(employee_id)) / (stddev(seniority_days) * stddev(salary)),
9       2),
10    2) as r2
11 from regression;

```

Utiliser ces informations pour afficher dans le graphique créé précédemment l'équation de la droite de régression et la valeur du R^2 .

